Обнаружение дипфейков на основе признаков DINOv2 и MobileNetV4: сравнительный анализ фото- и видеоклассификации

Авторы: Д.А. Перина, В.А. Мельников к.э.н.
Учреждение: ЧелГУ

Аннотация

В работе исследуется задача автоматического обнаружения синтетических (deepfake) лиц на фотографиях и видеозаписях с применением двух семейств нейронных сетей — самонаблюдаемого трансформера DINOv2 и лёгкой сверточной сети MobileNetV4. Обучение проводилось на объединенном наборе данных из 43762 видеозаписей, включающем публичные бенчмарки FaceForensics++, Celeb-DF, DFDC, DeepFaceDetection, а также собственные материалы, синтезированные с помощью алгоритмов замены лиц (inswapper) и диффузионных моделей (Stable Diffusion XL). Предлагается двухуровневый подход: на первом уровне обучается фреймовый классификатор, распознающий поддельные лица на отдельных изображениях; на втором — видеоклассификатор, агрегирующий признаки по 16 кадрам через временно́е усреднение. Лучшая модель на основе DINOv2 достигает ROC-AUC = 0.9988 на тестовой выборке видеозаписей при общей точности 98.30%, что превосходит аналогичную модель на основе MobileNetV4 на 1.6 процентных пункта. На уровне отдельных кадров фотоклассификатор DINOv2 демонстрирует полноту 99.51% для класса «реальные» и 99.73% для класса «поддельные».

Ключевые слова: обнаружение дипфейков, DINOv2, MobileNetV4, самонаблюдаемое обучение, видеоклассификация, визуальный трансформер, FaceForensics++, DFDC

1. Введение

Технологии синтеза лиц на основе глубокого обучения (deepfake) развиваются стремительно: современные диффузионные модели и алгоритмы замены лиц позволяют создавать фотореалистичные

видеозаписи, в которых лицо одного человека наложено на тело другого с высокой степенью правдоподобия. Подобный контент несет серьезные угрозы: от дискредитации публичных лиц и распространения дезинформации до мошенничества с использованием биометрической аутентификации [1, 2].

Задача обнаружения дипфейков (deepfake detection) формулируется как бинарная классификация: по входному изображению или видеозаписи необходимо определить, является ли лицо в кадре реальным или синтетическим. Сложность задачи обусловлена тем, что современные методы генерации постоянно совершенствуются, что ведёт к гонке между методами синтеза и детекции. Кроме того, качество изображения, освещение, степень компрессии видео и разнообразие алгоритмов подделки делают задачу принципиально неоднородной [3].

В данной работе предлагается и экспериментально исследуется двухуровневая система обнаружения дипфейков:
- фреймовый уровень — классификация отдельных кадров-лиц;
- видеоуровень — агрегирование признаков по последовательности кадров одного видео.

Для обоих уровней сравниваются два типа бэкбонов: трансформерный (DINOv2 ViT-S/14) и свёрточный (MobileNetV4-Conv-Medium). Модели обучаются на гетерогенном датасете, включающем несколько публичных бенчмарков и оригинальные данные, синтезированные методами замены лиц и диффузионных моделей.

2. Обзор предшествующих работ

Ранние подходы к обнаружению дипфейков опирались на явные визуальные артефакты — мерцание по краям лица, неестественное моргание, несогласованность текстуры [4]. По мере совершенствования генеративных моделей исследователи перешли к обучению нейронных сетей, способных находить скрытые статистические паттерны. В работе [5] показано, что свёрточные сети (VGG, Inception, Xception) хорошо обобщаются внутри одного метода синтеза, но теряют качество при

переносе на неизвестные атаки. Датасет FaceForensics++ [6] стал стандартным бенчмарком: он охватывает четыре метода манипуляции и уровни сжатия, что стимулировало разработку более обобщаемых детекторов.

Трансформерные архитектуры открыли новые возможности: ViT-based детекторы [7] фиксируют глобальные зависимости между патчами лица, недоступные для локальных свёрток. Самонаблюдаемое обучение (self-supervised learning), в частности семейство DINO/DINOv2 [8], позволяет предобучать мощные признаковые экстракторы на миллиардах изображений без разметки, что особенно ценно при ограниченных объёмах данных о дипфейках.

На уровне видеоанализа перспективными остаются два направления: (1) анализ темпоральной непоследовательности — рассинхронизации мимики, движений головы и артикуляции [9]; (2) агрегирование пространственных признаков по кадрам с помощью LSTM, Transformer-энкодеров или простого усреднения [10]. Настоящая работа исследует последний подход в сочетании с современными бэкбонами.

3. Набор данных

3.1 Источники данных

Обучение проводилось на объединенном датасете из нескольких источников (табл. 1). Публичная часть включает:

- FaceForensics++ (F++) [6] — четыре метода манипуляции: Deepfakes, FaceSwap, Face2Face, FaceShifter;
- Celeb-DF [11] — высококачественные дипфейки с лицами знаменитостей;
- DFDC (DeepFake Detection Challenge) [12] — крупный датасет с разнообразными условиями съёмки;
- DeepFaceDetection (DFD) — манипулированные и оригинальные видео.

Оригинальная часть включает:

- Dataset_Dasha_inswapper / Dataset_Real_1_inswapper — синтезированы алгоритмом замены лиц InsightFace (inswapper_128);
- Dataset_Dasha1_sdxl / Dataset_Real_0_sdxl — синтезированы с использованием Stable Diffusion XL + IP-Adapter для сохранения идентичности лица;
- Real_new_video, Real_Dasha, Real_Dasha1 — оригинальные записи реальных лиц.

Таблица 1. Распределение данных по разбивкам

Разбивка	Реальные	Поддельные	Всего
Train	13 213	9 313	22 526
Val	5 665	3 983	9 648
Test	1 936	3 481	5 417
Итого	20 814	16 777	37 591

Тестовая выборка намеренно несбалансирована (реальных в 1.8 раза больше), что соответствует реалистичному сценарию применения.

3.2 Предобработка

Для видеоданных применялась следующая процедура нормализации:
1. Детекция лиц с помощью InsightFace (buffalo_s) в каждом кадре;
2. Вычисление медианного ограничивающего прямоугольника (bounding box) по всем кадрам видео;
3. Обрезка лицевой области с отступом 40% от размера bbox;
4. Фильтрация некачественных кадров: чёрные (mean < 10), пересвеченные (mean > 245), однородные (std < 5);
5. Извлечение до 64 кадров на видео; кадры размером менее 256 px отбрасываются.

Для фотодатасета использовалась та же процедура детекции лиц с дополнительной нормализацией ориентации по ключевым точкам

(MediaPipe landmarks). Из каждого видео извлекалось 5 равномерно распределенных кадров.

4. Предлагаемый метод

4.1 Фреймовые классификаторы (Photo-level)

DINOv2-фото. В качестве признакового экстрактора используется DINOv2 ViT-S/14 [8] — трансформер с 22.1 млн параметров, предобученный самонаблюдаемым методом на датасете LVD-142M. Входное изображение масштабируется до 518×518 пикселей. Поверх заморожённого бэкбона добавляется классификатор:

Linear(384 → 256) → ReLU → Dropout(0.3) →
Linear(256 → 128) → ReLU → Dropout(0.2) →
Linear(128 → 2)

Стратегия обучения: первые 4 эпохи обучается только классификатор; начиная с эпохи 5 размораживаются последние 3 блока трансформера. Оптимизатор — AdamW, функция потерь — CrossEntropyLoss. Скорость обучения классификатора в 10× выше, чем бэкбона.

MobileNetV4-фото.Бэкбон `mobilenetv4_conv_medium.e500_r256_in1k` (~ 9.7 млн параметров, входной размер 224×224). Аналогичная двухфазная стратегия: заморозка на эпохах 0–2, разморозка с эпохи 3.

4.2 Видеоклассификаторы (Video-level)

Для видеоуровня применяется единая схема агрегирования признаков (рис. 1):

1. Равномерная выборка T = 16 кадров из видео; если видео короче — последний кадр дублируется;

2. Применение бэкбона (DINOv2 или MobileNetV4) к каждому кадру независимо → матрица признаков [B, T, d];
3. Temporal mean pooling: усреднение по оси T → вектор [B, d];
4. Классификатор:

DINOv2: Linear(384 → 256) → ReLU → Dropout(0.3) →
Linear(256 → 128) → ReLU → Dropout(0.2) → Linear(128 → 2)

MobileNetV4: Linear(960 → 512) → ReLU → Dropout(0.3) →
Linear(512 → 256) → ReLU → Dropout(0.2) → Linear(256 → 2)

Видео-ориентированное разбиение данных. Для исключения утечки данных разбивка train/val выполняется на уровне видео, а не кадров: все кадры одного видео попадают только в одну из подвыборок.

Аугментации. Для обучения применялись: горизонтальное отражение (p=0.5), случайный поворот (±10°), ColorJitter (яркость/контраст/насыщенность ±0.2), Gaussian Blur (p=0.3), Random Sharpness (p=0.3). Одни и те же параметры аугментации применялись ко всем кадрам видео, чтобы не вносить искусственных межкадровых различий.

4.3 Детали обучения

Все эксперименты проводились на GPU NVIDIA GeForce RTX 3090 (24 ГБ VRAM) с использованием фреймворка PyTorch Lightning. Параметры обучения представлены в таблице 2:

Таблица 2 - Параметры обучения

Параметр	DINOv2	MobileNetV4
Размер входа	518×518	224×224

Batch size	4	16
Grad. accumulation	4	4
LR (бэкбон) |	1e-5	1e-4
LR (голова)	1e-4	1e-3
Оптимизатор	AdamW	AdamW
Эпоха разморозки	5	3
Max epochs	50	50
Precision	AMP 16-bit	AMP 16-bit
Early stopping	patience=5 (val_roc_auc)	patience=5

5. Результаты экспериментов

5.1 Фреймовые классификаторы

На тестовом наборе из 9733 фотографий (Real: 3 084, Fake: 6 649) фотоклассификаторы показали следующие результаты (табл. 2):

Таблица 3. Результаты фреймовых классификаторов (порог = 0.5)

Метрика	DINOv2-фото	MobileNetV4-фото
Полнота Real	99.51%	94.20%
Полнота Fake	99.73%	89.60%
val ROC-AUC (лучшая эпоха)	0.999	0.962

DINOv2 демонстрирует значительное преимущество, особенно на сложных источниках: F++_FaceSwap (98.04% vs 73.33%), Dataset_Dasha1_sdxl (95.83% vs 70.83%), F++_FaceShifter (98.07% vs 83.40%). Худший результат MobileNetV4 на указанных категориях

объясняется тем, что артефакты диффузионной генерации и современные алгоритмы замены лиц работают на частотах и семантических уровнях, доступных для глобального внимания трансформера, но плохо улавливаемых локальными сверточным фильтрами.

5.2 Видеоклассификаторы

На тестовой выборке из 5417 видео сравниваются две видеомодели (табл. 3):

Таблица 4. Результаты видео классификаторов на тестовой выборке

Метрика	DINOv2-видео	MobileNetV4-видео
ROC-AUC	0.9988	~0.980
Общая точность	98.30%	96.64%
Точность (Fake)	97.74%	96.73%
Точность (Real)	97.47%	96.49%

Таблица 5. Точность DINOv2-фото по источникам данных (тестовая выборка)

Источник	Класс	Видео	Точность
Real/Real_new_videos	Real	1513	100.00%
Real/Real_dive	Real	659	100.00%
Real/Real_Data1	Real	22	100.00%
Real/DFD_original	Real	3	100.00%
Real/Real_0	Real	337	98.81%
Real/Real_1	Real	337	98.48%

Real/F++	Real	252	97.62%
Real/Real_Data	Real	34	97.06%
Fake/Celeb_fakes	Fake	5559	100.00%
Fake/F++_Deepfakes	Fake	255	99.61%
Fake/F++_FaceShifter	Fake	259	98.07%
Fake/F++_FaceSwap	Fake	255	98.04%
Fake/Dataset_Real_1_inswapper	Fake	256	98.05%
Fake/Dataset_Data_inswapper	Fake	36	97.22%
Fake/Dataset_Data1_sdxl	Fake	24	95.83%

Фотомодель DINOv2 достигает 100% на крупнейших источниках (Real_new_videos, Real_dive, Celeb_fakes). Наибольшую сложность представляют SDXL-синтезированные лица (95.83%) — артефакты диффузионной генерации частично схожи с высокочастотными признаками реальных лиц.

Таблица 5. Точность DINOv2-видео по источникам данных (тестовая выборка)

Источник	Класс	Видео	Точность
F++_Deepfakes	Fake	100	100.00%
F++_FaceSwap	Fake	100	100.00%
Dataset_Data1_sdxl	Fake	167	100.00%
Dataset_Data_inswapper	Fake	137	100.00%
Celeb_fakes	Fake	1619	98.95%
F++_FaceShifter	Fake	100	94.00%
Real_new_video	Real	1251	99.60%

Real_Data	Real	136	99.26%
Real/F++	Real	100	98.00%
Real/DFDC_real	Real	60	93.33%
Real/DFD_original	Real	37	91.89%
Real/Celeb	Real	60	88.33%

Наибольшая доля ошибок у обеих видеомоделей приходится на источники Real/Celeb и Real/DFD_original: реальные видео этих датасетов содержат сильное сжатие и нестандартную постобработку изображений, артефакты которой схожи с признаками синтеза.

5.3 Сравнение архитектур

Трансформерный бэкбон (DINOv2) превосходит сверточный (MobileNetV4) во всех четырех постановках задачи. Наиболее выраженное преимущество наблюдается на фотоуровне: разрыв достигает 25 п.п. на отдельных сложных источниках. На видеоуровне разрыв сокращается до 1.6–2 п.п., что объясняется эффектом усреднения по T=16 кадрам — временно́е усреднение сглаживает ошибки на уровне отдельных кадров и компенсирует часть слабостей сверточного бэкбона.

6. Обсуждение

Обобщаемость. Результаты подтверждают, что признаки DINOv2, обученные самонаблюдаемым методом на разнообразных изображениях, обладают высокой переносимостью на различные методы синтеза — включая диффузионные модели (sdxl), которые не были представлены в предобучении бэкбона. Это свойство особенно ценно в условиях постоянного появления новых методов генерации.

Ложные срабатывания на реальных лицах. Основная проблема — ложные тревоги на `Real/Celeb` (88.33% для DINOv2-видео). Анализ ошибок

показывает, что видео данного источника подверглись многократной перекодировке, что создаёт блочные артефакты JPEG, схожие с артефактами синтеза. Решением может служить аугментация сжатием (JPEG compression augmentation) в процессе обучения.

Ограничения подхода. Mean pooling по 16 кадрам игнорирует темпоральную динамику (мимику, движения головы), которая сама по себе может служить признаком синтеза. Альтернативой является использование Transformer-энкодера над последовательностью признаков, обученного улавливать межкадровые зависимости.

Диффузионные методы. Синтезированные с помощью SDXL лица (`Dataset_Dasha1_sdxl`) распознаются с точностью 100% на видеоуровне. Вероятно, это связано с характерными артефактами диффузионного процесса на высоких частотах, хорошо фиксируемыми трансформерным вниманием. Данный результат важен в контексте распространения контента, созданного современными генеративными ИИ.

7. Заключение

В работе представлена двухуровневая система обнаружения дипфейков, основанная на бэкбонах DINOv2 и MobileNetV4, и обученная на гетерогенном датасете из более 37 000 видеозаписей с разнообразными методами синтеза лиц. Предложенный подход на основе DINOv2 достигает ROC-AUC = 0.9988 на видеоуровне и ROC-AUC = 0.999 на фотоуровне. Сравнение с MobileNetV4 подтверждает преимущество трансформерных архитектур с самонаблюдаемым предобучением. Основным направлением дальнейших исследований является разработка темпоральных моделей, учитывающих межкадровую динамику лица, а также улучшение обобщаемости на видео с высокой степенью компрессии.

Список литературы

1. Tolosana R., Vera-Rodriguez R., Fierrez J. et al. Deepfakes and beyond: A survey of face manipulation and fake detection // Information Fusion. — 2020. — Vol. 64. — P. 131–148.

2. Mirsky Y., Lee W. The creation and detection of deepfakes: A survey // ACM Computing Surveys. — 2021. — Vol. 54, № 1. — P. 1–41.

3. Verdoliva L. Media Forensics and DeepFakes: An Overview // IEEE Journal of Selected Topics in Signal Processing. — 2020. — Vol. 14, № 5. — P. 910–932.

4. Li Y., Chang M.-C., Lyu S. In ictu oculi: Exposing AI created fake videos by detecting eye blinking // Proc. IEEE WIFS. — 2018. — P. 1–7.

5. Rossler A., Cozzolino D., Verdoliva L. et al. FaceForensics: A large-scale video dataset for forgery detection in human faces // arXiv:1803.09179. — 2018.

6. Rossler A., Cozzolino D., Verdoliva L. et al. FaceForensics++: Learning to detect manipulated facial images // Proc. ICCV. — 2019. — P. 1–11.

7. Zhao H., Zhou W., Chen D. et al. Multi-attentional deepfake detection // Proc. CVPR. — 2021. — P. 2185–2194.

8. Oquab M., Darcet T., Moutakanni T. et al. DINOv2: Learning robust visual features without supervision // Transactions on Machine Learning Research. — 2024.

9. Haliassos A., Vougioukas K., Petridis S., Pantic M. Lips don't lie: A generalisable and robust approach to face forgery detection // Proc. CVPR. — 2021. — P. 5039–5049.

10. Zheng J., Bao W., Chen D. et al. Exploring temporal coherence for more general video face forgery detection // Proc. ICCV. — 2021. — P. 15044–15054.

11. Li Y., Yang X., Sun P. et al. Celeb-DF: A large-scale challenging dataset for deepfake forensics // Proc. CVPR. — 2020. — P. 3207–3216.

12. Dolhansky B., Bitton J., Pflaum B. et al. The DeepFake Detection Challenge (DFDC) dataset // arXiv:2006.07397. — 2020.